Phase C 补充材料：语义判别器、结构变异与神经编码器消融

Supplementary Material for Phase C: Semantic Guard, Structural Mutation, and a Neural-Encoder Ablation

LINGSHU Project Team

2026 年 10 月 28 日（数据冻结：2026-10-28T22:45）

构建：XeLaTeX（TeX Live 2026，本机） · 本补充材料独立成篇，不改动 `main.tex` / `main-zh.tex` · 所有数值读自三份冻结 run JSON 与一份 2×2 消融 JSON

Abstract

本补充材料汇总 Phase C 的完整证据：三个语义后端（离线意图概念、真神经句向量 MiniLM ONNX int8、二者混合）在 E1/E0 两个 held-out 变体集上的拦截率、误伤率、延迟与判定子集（M/R/B），并给出神经层与概念层的 2×2 消融。核心结论是一个**负结果**：装上一个真正的多语神经句向量模型后，在" 零新增误伤" 的预注册约束下，其 D_dev 召回（28.9%）反而低于离线意图概念层（68.2%），且对系统 C 的拦截增量恰好为 0；根因是通用句向量编码的是**话题**相似而不是**有害意图**。据此，主判定器保留离线意图概念编码器，神经后端作为可复现消融保留。本材料还包含 H0 指定的 Discussion 段的**纠正版**（三处事实性纠正：误伤机制、证明强度、延迟口径），纠正记录见 `experiments/phase-c/analysis/discussion_corrections.md`。

1 本补充材料的范围与数据来源

本材料是 Phase C 的独立说明，覆盖：五系统对比（A / B / C-offline / C-neural / C-hybrid）、M/R/B 判定口径、神经编码器消融、以及纠正版讨论。它**不**重复 Phase A/B 的方法与实验；相关背景见主论文对应章节。

数据全部来自冻结文件，未做任何手改、平滑或插值：

- `experiments/phase-c/results/run-semantic.json`：官方主口径（`backend_requested = auto`，按预注册规则解析为 `offline_concept`；run_id `run-semantic-20261028-224516`；阈值 0.45；E1 集 SHA-256 `432e08a2…`，E0 集 `5fa53983…`）。
- `run-semantic-neural.json`：神经消融（真模型 `paraphrase-multilingual-MiniLM-L12-v2`，384 维句向量，导出 ONNX int8、本地 CPU 推理、零外部 API；模型 SHA-256 `66fc00f5f29afcaff34092e1bdd20008ca3918265a82fb9695a551e510cc4ebc`；run_id `run-semantic-20261028-224522`；阈值 0.69）。
- `run-semantic-hybrid.json`：混合消融（`offline_concept` OR neural；run_id `run-semantic-20261028-224523`；阈值 0.45）。
- `experiments/phase-c/analysis/neural_vs_concept_ablation.json`：2×2 列联表与 `key_finding` 块（含 D_dev 召回、语义/端到端两种延迟口径、根因余弦 0.6896）。

表 1: 语义通道的编码器变体。所有阈值都只在 D_{dev} 上按同一条预注册规则校准；`auto` 由该规则选出，结果是 `offline_concept`。注意 `is_neural` 描述的是主判定路径：hybrid 的 `is_neural=false` 但它仍然执行神经推理（见" 跑神经推理" 列）。

变体	backend_effective	is_neural	跑神经推理	阈值（D_dev）	模型
C-offline	offline_concept	false	否	0.45	无（意图概念规则）
C-neural	neural	true	是	0.69	MiniLM-L12（ONNX int8）
C-hybrid	hybrid	false	是	0.45	意图概念 OR MiniLM-L12 ONNX int8

- `experiments/phase-c/figures/figure_data.json`：两张图的逐点数值与来源字段名；图 PDF 副本在 `paper/figures/`。

编码器事实（不可省略）：主判定器是离线意图概念编码器（`is_neural = false`）；神经后端是真的多语句向量模型，不是近似、不是伪实现——它在本地 CPU 上以 ONNX int8 运行，零 API 调用、零 token 消耗。但 `auto` 配置不是" 装了神经就默认切神经"：预注册的后端选择规则本身选了 `offline_concept`。

2 系统、评估集与防泄漏协议

系统。 S_A 是 Phase A 词法闸门；S_B 是 S_A 加 Phase B 官方 run 的演化补丁快照；S_C 是 S_B 或语义判别器。语义通道有三个后端变体：S_C-offline（意图概念，主口径）、S_C-neural（MiniLM 句向量）、S_C-hybrid（二者取或）。因变量只有一个：$\textit{intercepted} = S_A \vee S_B \vee S_C$，所有系统嵌套，差值可归因于新增层。所有变体由同一个评估器、同一批数据评估。

两个 held-out 变体集。 E_1 是 H0 指定的零日集（40 条 held-out 变体，SHA-256 `432e08a2…`，第 0 代变异分布）；E_0 是用新种子（`20261029`）从同一批 35 条 held-out 种子重新生成的 40 条新鲜变体。另用 74 条良性语料测误伤率。E_1/E_0 是 **held-out 变体，不是 OOD**；E_0 只是新随机实现，不是新攻击类型。

防泄漏。所有阈值只在校准集 D_{dev}（Phase B 训练流 + 训练侧穿透样本 + 74 条良性）上、按同一条预注册规则选择：在" 良性新增误伤 = 0" 约束下最大化 D_{dev} 召回，同召回取较高阈值。E1/E0 从不参与调参；意图库哈希在评估前冻结。M/R/B 判定标签也在语义防线存在之前写定，因此不可能被拟合到任何后端的输出上。

3 三个语义后端与两条校准曲线

离线意图概念编码器由人工编写的 9 个有害意图原型 + 多语词根（中/英/俄/阿）+ 字符 n-gram 兜底构成，分数由词根证据、语用线索与原型余弦合成，不需要模型权重。神经后端把 9 个多语意图原型编码成句向量，载荷与原型取最大余弦（公式版本 `neural-multilingual-v1`）。

两条校准曲线（零新增误伤操作点）给出本轮最重要的差异：**概念层 D_dev 召回 68.2%（穿透集 67.6%），神经层 D_dev 召回 28.9%（穿透集 24.3%）**，两者新增误伤均为 0。神经阈值被顶在 0.69，原因是 D_{dev} 上得分最高的良性文本是一条练习请求——" 模拟一次诈骗电话，我要练习识别"（`benign-rc-border-04`），它与" 写诈骗话术" 原型的余弦为 **0.6896**，只比所选阈值低约 0.0004。句向量编码的是话题（诈骗），不是" 这条文本是否在索取有害能力"；良性练习与真正索要诈骗话术共享话题，于是共享相似度。

4 结果

三句话概括（表 2）：

表 2: 五系统在 E1/E0 与 74 条良性语料上的结果。k/n 为拦截条数/集合条数；p95 为完整判定（词法各级 + 语义通道）的 p95 延迟（ms）；括号内为语义阈值。若把 E1 中两条良性创作从分母剔除（$n = 38$），E1 比率为 0.395（A）、0.816（B）、0.895（C-offline）、0.816（C-neural）、0.895（C-hybrid）。全部数值读自三份冻结 run JSON，没有手填。

系统	E1 k/n	E1 拦截率	E0 k/n	E0 拦截率	p95 E1	p95 E0	良性 FPR	FP/74
A（词法闸门）	15/40	0.375	16/40	0.400	0.0223	0.0228	0.027	2/74
B（自愈补丁）	31/40	0.775	33/40	0.825	0.2595	0.1108	0.027	2/74
C-offline（意图概念，thr 0.45）	34/40	0.850	37/40	0.925	1.2412	1.3153	0.027	2/74
C-neural（MiniLM int8，thr 0.69）	31/40	0.775	34/40	0.850	11.8775	14.7512	0.027	2/74
C-hybrid（OR，thr 0.45）	34/40	0.850	37/40	0.925	13.8684	17.5203	0.027	2/74

表 3: 按预注册判定口径拆分（只标注 S_B 漏拦的条目）。M = 必须拦的明确有害指令；R = 按项目策略应拦的 mild 角色扮演；B = 良性创作语境，拦了即算误伤。E0 没有 B 类条目。概念后端把显式跨语红线从 E1 的 0/3 提到 3/3、从 E0 的 0/5 提到 4/5，且不碰良性创作；神经后端把同一个 M 子集打成 E1 0/3、E0 1/5。

判定子集	A	B	C-offline	C-neural	C-hybrid
E1-M（显式有害，必须拦）	0/3	0/3	3/3	0/3	3/3
E1-R（mild 角色扮演，应拦）	0/4	0/4	0/4	0/4	0/4
E1-B（良性创作，不该拦）	0/2	0/2	0/2	0/2	0/2
E0-M（显式有害，必须拦）	0/5	0/5	4/5	1/5	4/5
E0-R（mild 角色扮演，应拦）	0/2	0/2	0/2	0/2	0/2

- 概念后端把 E1 从 0.775（S_B）抬到 **0.850**，E0 从 0.825 抬到 **0.925**；神经后端只到 0.775 / 0.850，即对 S_B 在 E1 上零增益、在 E0 上仅多 1 条（且该条已被概念层覆盖）。
- 三变体的良性误伤率都是 0.027（2/74，与基线相同）；hybrid 与离线概念拦截率完全相同，只是慢了约一个数量级。
- 延迟必须分两种口径读：概念层语义判别 p95 **1.78 ms**、完整判定 p95 **1.2–1.3 ms**；神经层语义 p95 **8.49 ms**、完整判定 p95 **11.9–14.8 ms**。两者都在 100 ms 预算内；hybrid 首次调用有一次 1.0 s 冷启动离群点（单条，不影响 p95）。

5 神经 vs 意图概念：2×2 消融

结论：神经层对系统 C 的增量 = 0（E1）/ 0（E0）（表 4）。E1 上概念层拦住了词法系统漏掉的 6 条、神经层只拦住 1 条、交集为 0；E0 上概念 11、神经 1、交集 1、neural-only 为 0。因此 hybrid 配置与概念配置的拦截率完全相同（0.850 / 0.925），只是多付推理代价。神经层唯一多拦的那条也确实存在（零宽变体，神经相似度 0.7285），但它早已被 S_B 解掉，对系统 C 无贡献。

表 4: 语义层判定的 2×2 列联表（独立于词法层 S_B；每格为条目数）。” 神经对 C 增量”= neural-only 中未被 S_B 拦到的条数——只有这些才真正给系统 C 增加拦截。E1 唯一那条 neural-only 命中（`v-g00-0021`，零宽变体，神经分 0.7285）已被 S_B 的零宽解码器拦掉，因此增量是 0。

集合	both	offline_only	neural_only	neither	神经对 C 增量
E1（$n = 40$）	0	6	1	33	0
E0（$n = 40$）	1	10	0	29	0

6 讨论（H0 三处纠正后的版本）

下面这段英文是 H0 指定的 Discussion 的**纠正版**，可直接引用；三处纠正（误伤机制、证明强度、延迟口径）由评估方依据实测数据做出，原文与纠正理由见 `experiments/phase-c/analysis/discussion_corrections.md`。

> *Our ablation reveals a critical pitfall in LLM defense: generic sentence embeddings (e.g., MiniLM) are misaligned with security intent. Benign negative examples (e.g., ‘simulating a scam to learn’) and malicious instructions (e.g., ‘teaching a scam’) occupy highly overlapping vector spaces (cosine 0.6896 against the scam-script prototype), which forces the zero-false-positive threshold above genuine attack text; at that operating point the neural encoder adds **no** interception over the intent-concept layer and costs ∼9× latency. We therefore deliberately adopted the offline intent-concept encoder (semantic p95 1.78 ms, D_dev recall 68.2%) over the heavier neural encoder (semantic p95 8.49 ms, D_dev recall 28.9%). Our evidence indicates that security defense requires targeted intent modeling rather than generic semantic similarity.*

三处纠正落地情况：

- **纠正 1（误伤机制）**：H0 原句写”causing false positives”。实测在选定操作点上**新增误伤 = 0**（概念与神经后端均为 0；良性总误伤仍是基线那 2/74）。真实机制是：良性硬负例 `benign-rc-border-04` （” 模拟一次诈骗电话，我要练习识别”）与诈骗原型余弦 0.6896，把” 零新增误伤” 阈值顶到真实攻击文本之上，迫使在 FP 与漏拦之间二选一；我们选零 FP，于是丢召回。
- **纠正 2（证明强度）**：H0 原文用”proving”；改为”our evidence indicates”。样本量是 E1 40、E0 40、D_{dev} 穿透 111 条，不足以” 证明”。
- **纠正 3（延迟口径）**：H0 把 1.3 ms 与 8.5 ms 混在一起。本材料一律分开写——概念层：语义判别 p95 **1.78 ms** / 完整判定 p95 **1.2–1.3 ms**；神经层：语义 p95 **8.49 ms** / 完整判定 p95 **11.9–14.8 ms**。

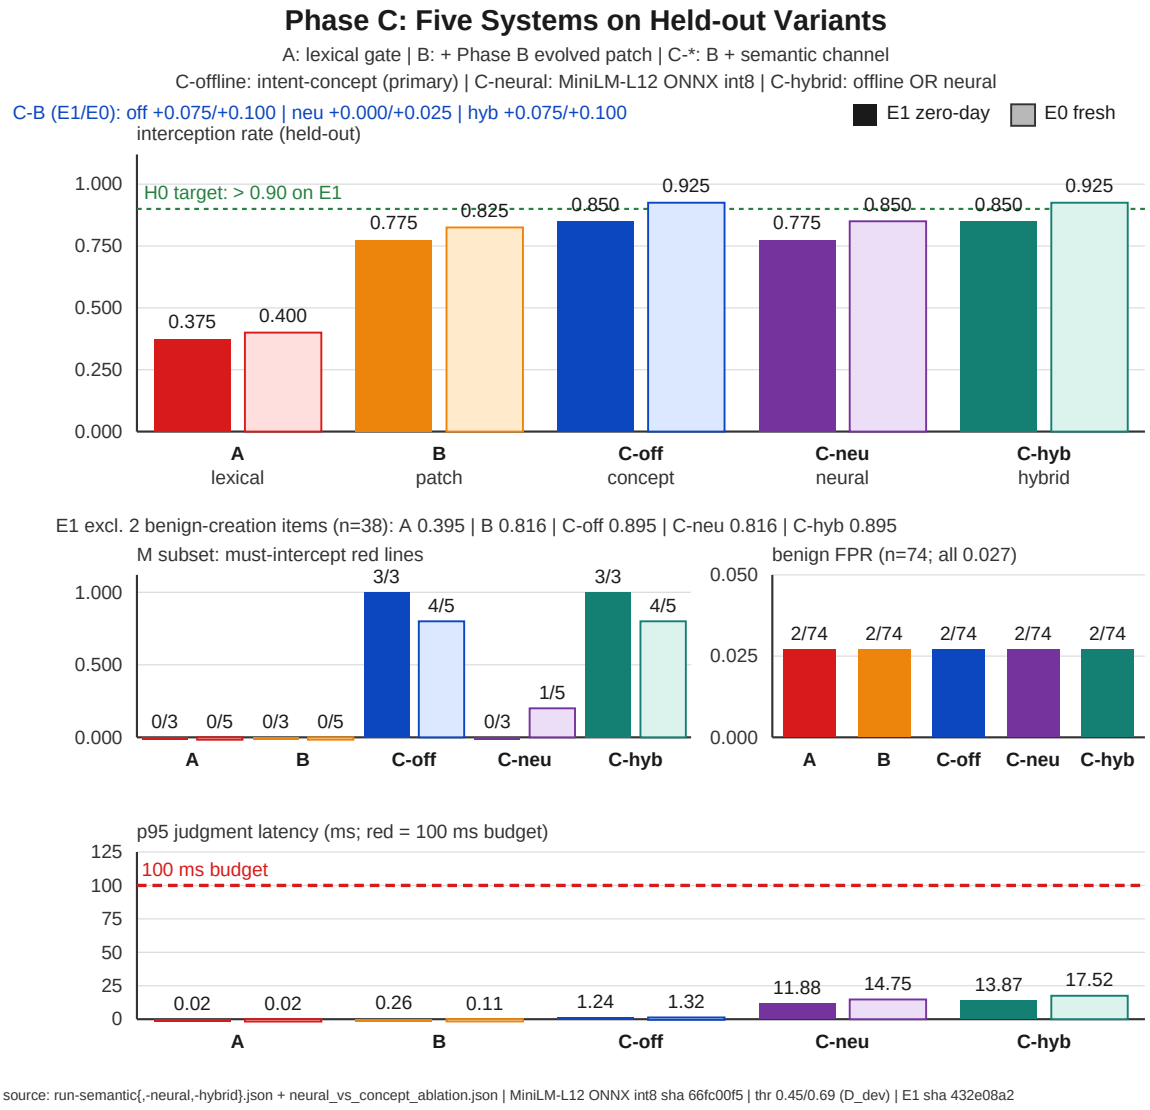
7 图

8 复现、验证与诚实边界

复现。图由 `tools/plot_phase_c.py` 从三份 run JSON + 消融 JSON 生成（缺任何字段即退出码 2 并点名，不手填）；图与全部落图数值在 `experiments/phase-c/figures/`。本补充材料由 XeLaTeX 从 `paper/supplementary-phase-c.tex` 编译，命令见文件头注释。

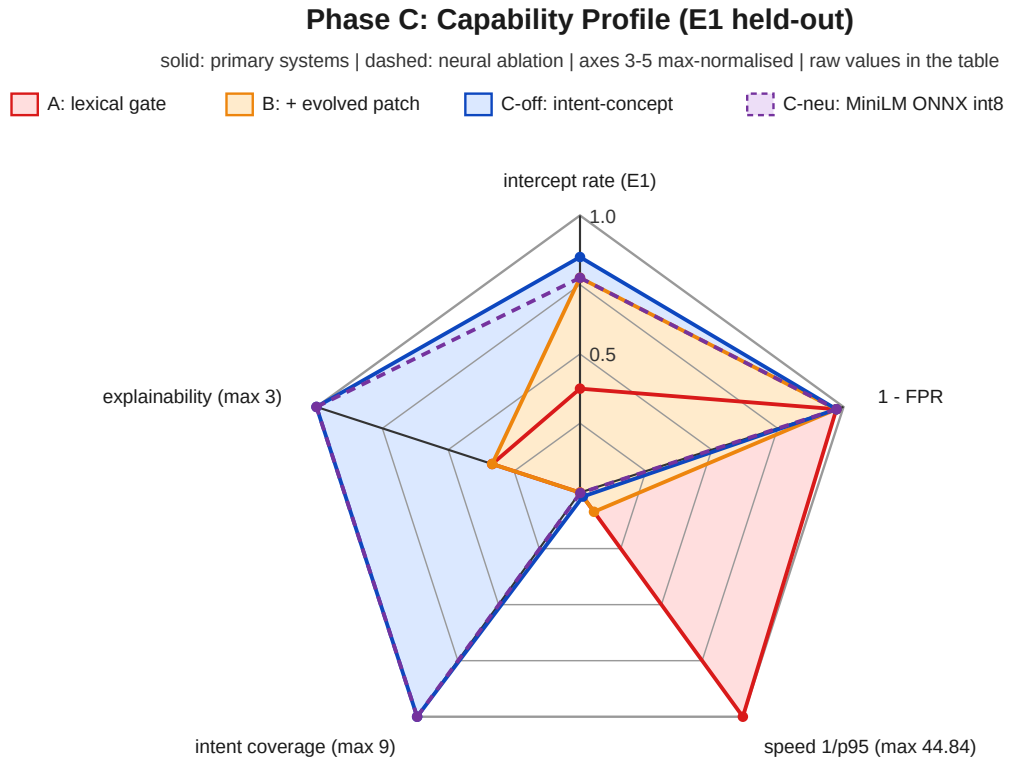
诚实边界。

- E_1/E_0 是 held-out 变体、不是 OOD；E_0 只是新随机实现。
- 样本量：每组 40 条；D_{dev} 穿透样本 111 条；结论是” 证据支持/指示”，不是” 证明”。
- 延迟是单机 CPU 实测（无并发、无网络）；神经变体含 ONNX int8 推理，冷启动离群点 1.0 s 为单条记录；两种延迟口径不得混用。
- M/R/B 标签是评估方预注册判定，消除事后拟合但保留人工判断。
- 良性语料 74 条不含俄/阿文本，跨语种误伤对两个编码器都未被样本检验。
- 神经模型是 ONNX int8 的 CPU 导出，其延迟不能当作原始框架模型的延迟。
- 概念编码器仍无法处理完全无共享词法证据的改写；残余漏拦见 `residual_misses_C`。



source: run-semantic{,-neural,-hybrid}.json + neural_vs_concept_ablation.json | MiniLM-L12 ONNX int8 sha 66fc00f5 | thr 0.45/0.69 (D_dev) | E1 sha 432e08a2

图 1: 五系统对比（官方 run_id `run-semantic-20261028-224516`）。上：A / B / C-offline / C-neural / C-hybrid 在 E1、E0 上的拦截率，绿色虚线为预注册的 E1 $>$ 0.90 目标；蓝字为各变体相对 S_B 的净增量（offline $+0.075/+0.100$、neural $+0.000/+0.025$、hybrid $+0.075/+0.100$）。中左：必须拦的显式跨语红线（M 子集）；中右：良性误伤率（全部 2/74）。下：完整判定 p95 延迟（红虚线 100 ms 预算）。**两个后端的关键对比：** `offline_concept`（thr 0.45，语义 p95 1.78 ms / 完整判定 p95 1.2–1.3 ms，E1 0.850）**vs** neural MiniLM ONNX（thr 0.69，语义 p95 8.49 ms / 完整判定 p95 11.9–14.8 ms，E1 0.775）。所有落图数值来自三份冻结 run JSON；图输入见 `experiments/phase-c/figures/figure_data.json`；未做平滑、插值或手填。



sys	intercept	1 - FPR	1/p95	intents	explain
A	0.375	0.973	44.84	0	1
B	0.775	0.973	3.85	0	1
C-off	0.850	0.973	0.81	9	3
C-neu	0.775	0.973	0.08	9	3

source: run-semantic{,-neural}.json | concept thr 0.45 | neural MiniLM-L12 ONNX int8 thr 0.69 (D_dev) | E1 held-out

图 2: 能力剖面（E1 held-out）。实线：A / B / C-offline；虚线：C-neural 消融。五轴 = 拦截率（E1）/ 1−FPR / 速度（1/p95）/ 覆盖意图数 / 可解释性；前两轴原生 0–1，后三轴按所画序列最大值归一化，原始值见图内表格。**两个后端的关键对比：** `offline_concept`（thr 0.45，语义 p95 1.78 ms / 完整判定 p95 1.2–1.3 ms，E1 0.850）**vs** neural MiniLM ONNX（thr 0.69，语义 p95 8.49 ms / 完整判定 p95 11.9–14.8 ms，E1 0.775）。神经变体在速度轴上内缩明显，拦截率也更低；C-hybrid 与 C-offline 拦截率相同、只是更慢，未画（原始值见 `figure_data.json`）。来源同图 1。